竞赛客服智能体搭建流程

2026年（第14届）“泰迪杯”数据挖掘挑战赛

主讲人：罗金萍

目录

01 实现思路

02 PDF文件信息提取

03 本地构建RAG应用

04 竞赛客服机器人开发

05 答疑环节

目录

01 实现思路

02 PDF文件信息提取

03 本地构建RAG应用

04 竞赛客服机器人开发

05 答疑环节

案例背景与目标

背景

- 随着国内学科和技能竞赛的增多，参赛者对竞赛相关信息的咨询需求不断上升。然而， 传统人工客服面临着效率低、成本高、服务不稳定和用户体验差等诸多问题。因此，**设计一 款智能客服机器人**，为赛事提供实时、高效、精准的信息查询服务，成为了迫切的需求。人工智能技术的发展为智能客服机器人的实现提供了有力支持。

案例背景与目标

目标

- 利用人工智能技术，结合提供的附件 1竞赛数据（PDF 格式文档），在数据整理、系统构建、算法设计和模型优化等环节进行处理与实现，设计出一款高效的智能客服机器人。
- 该机器人需要具备以下功能：**回答基础信息查询、进行统计分析查询，并能够处理用户提出的开放性问题**。
- 竞赛客服机器人搭建完成后，可回答附件 2 的问题，开展功能测试。

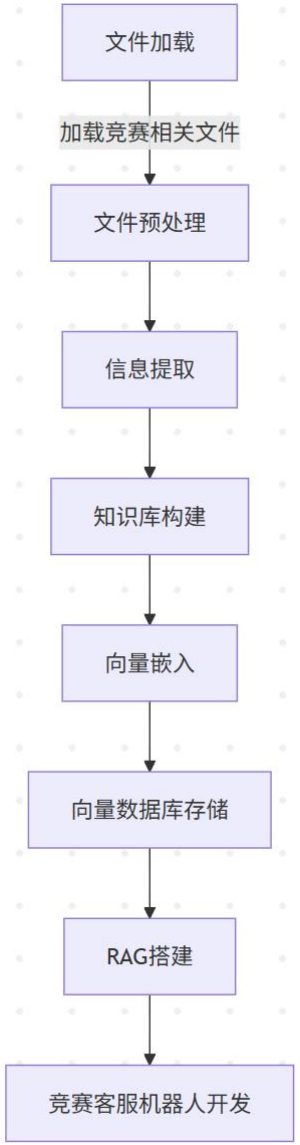

补充说明

- 本项目电脑配置要求较高，部分代码需要在GPU环境下运行。

目录

01 实现思路

02 PDF文件信息提取

03 本地构建RAG应用

04 竞赛客服机器人开发

05 答疑环节

PDF文件信息提取

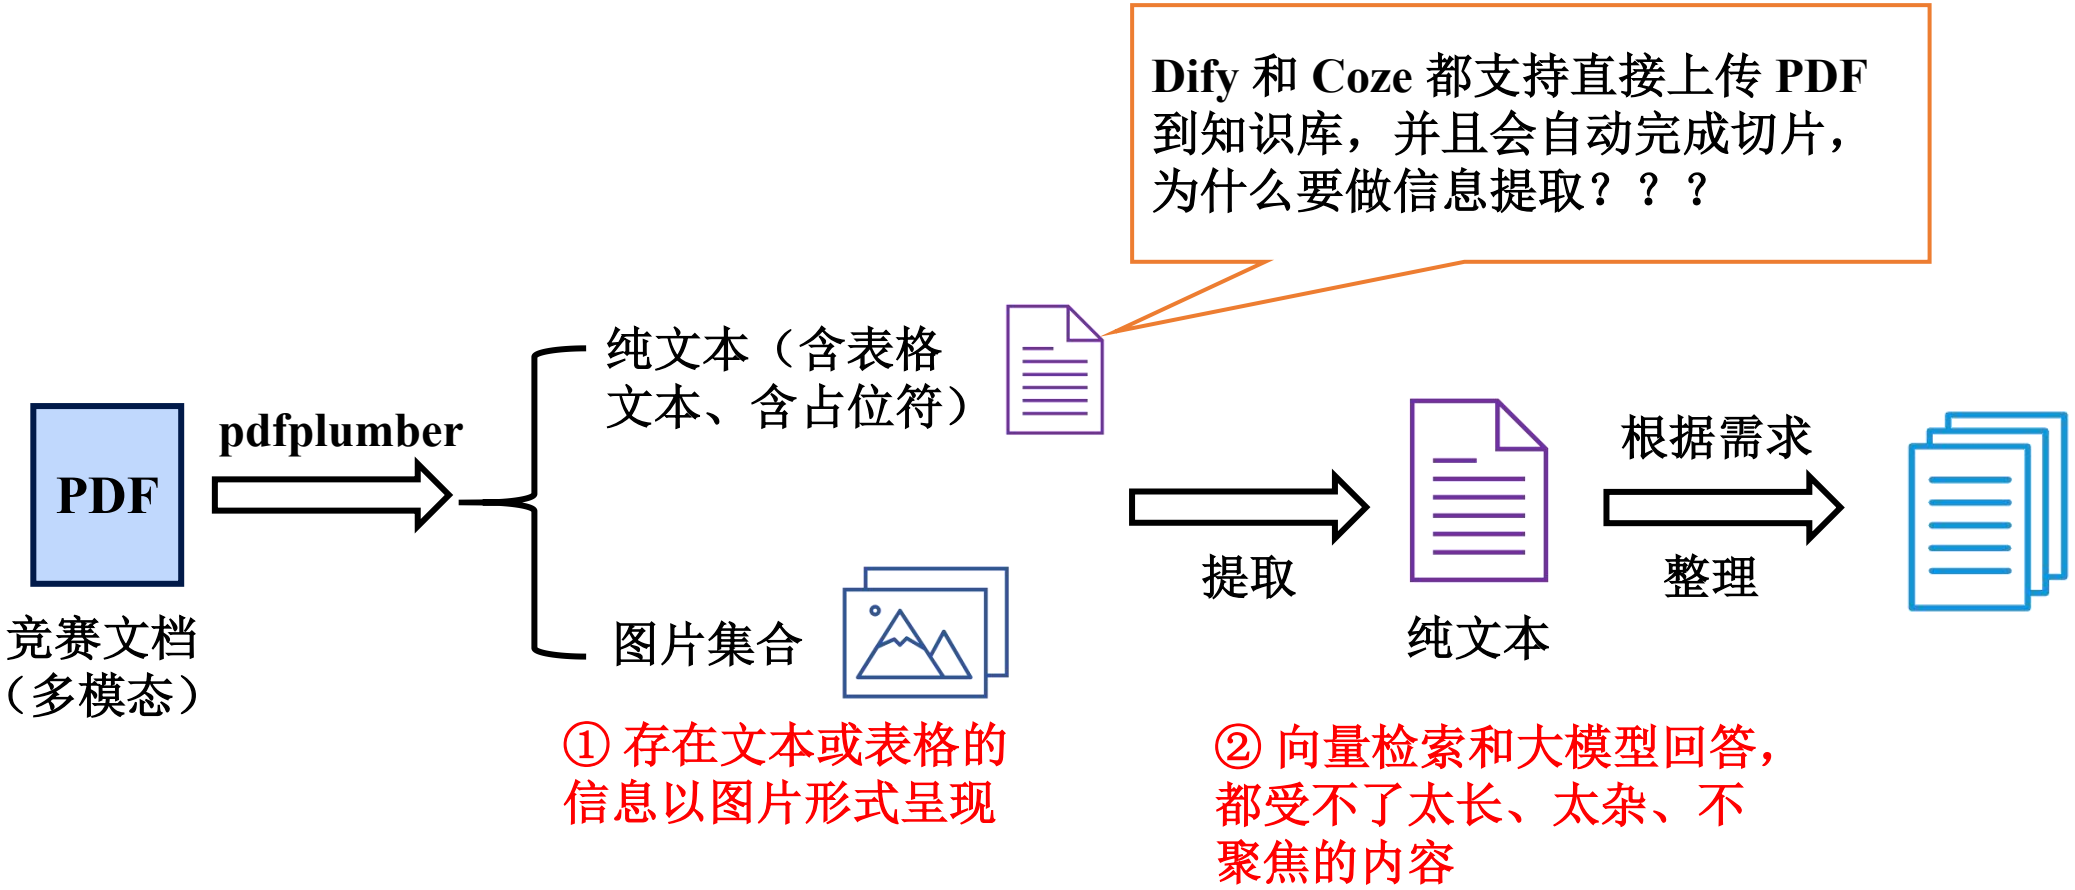
Dify 和 Coze 都支持直接上传 PDF 到知识库，并且会自动完成切片，为什么要做信息提取？？？
PDF
竞赛文档（多模态）
pdfplumber
纯文本（含表格文本、含占位符）
图片集合
提取
纯文本
根据需求
整理
① 存在文本或表格的信息以图片形式呈现
② 向量检索和大模型回答，都受不了太长、太杂、不聚焦的内容

PDF文件信息提取

- 从PDF文件中提取信息，根据文件类型（文本型或扫描图像型）和提取内容（文本、表格、图片或特定页面），有多种方法可供选择。
- 以下是针对不同需求的实用方案总结：
  - **可编辑的PDF（文本型）**：这类PDF直接包含文本数据，无需OCR，提取速度快且准确。
  - **扫描件或图片型PDF**：本质是图片，必须使用OCR（光学字符识别）技术将图像中的文字转换为可编辑文本。
  - **PDF表格提取**：规则驱动方法（适用于有边框或清晰空白的表格）；深度学习方法（适用于无边框、复杂布局的表格）
  - **PDF图片提取**：使用PyMuPDF可以提取PDF中的嵌入图像对象。
  - ……

PDF文件信息提取

直接文本提取 (Text Extraction)

- **适用场景：** 纯文本PDF（如规则文档、无复杂排版的文本文件）
- **常用工具：** PyPDF2, pdfplumber, PyMuPDF
- **核心优势：** 开发简单，处理速度快，可直接获取结构化文本
- **主要局限：** 无法处理扫描件、图片内嵌PDF；复杂排版支持差

OCR 图像识别 (Optical Character Recognition)

- **适用场景：** 扫描件PDF、图片内嵌PDF、包含手写/印章的文档
- **常用方案：** Tesseract + OpenCV, 百度/阿里/腾讯云OCR API
- **核心优势：** 适用范围广，可识别图像、手写体等视觉文字
- **主要局限：** 处理速度慢；识别精度受图像质量影响；文本结构信息易丢失

PDF文件信息提取

中国工业与应用数学学会

China Society for Industrial and Applied Mathematics

“2022 高教社杯全国大学生数学建模竞赛”报名第一次通知

数模竞赛[2022-01]号

各赛区组委会，各高等院校：

为了培养学生的创新意识及运用数学方法和计算机技术解决实际问题的能力，中国工业与应用数学学会全国大学生数学建模竞赛组委会决定举办 2022 高教社杯全国大学生数学建模竞赛（以下简称竞赛），欢迎各高等院校按照竞赛章程、参赛规则及有关规定组织同学报名参赛。

1．2022 年竞赛的时间确定为 9 月 15 日（周四）18 时至 9 月 18 日（周日）20 时。

2．参赛者以 3 名大学生组成一队（**鼓励不写指导教师**），通过学校教务部门向所在赛区组委会报名，再由赛区组委会向全国组委会报名。若所在地区尚未成立赛区，由学校直接向全国组委会报名。向全国组委会报名的截止日期为 9 月 12 日（周一）20 时。

3．报名采用网上报名方式。**境内和澳门特别行政区**的高校请使用竞赛管理系统报名（https://cumcm.cnki.net）；**香港特别行政区**的高校请与 HKSIAM（https://www.hksiam.org.hk）联系参赛事宜（邮箱：immc.committee@gmail.com）；**其他地区**高校请访问 CUMCM（English Version）（http://en.mcm.edu.cn），按相应要求注册参赛。

4．竞赛分为本科组和专科组进行。**本科学生只能参加本科组竞赛，不能参加专科组竞赛。专科（高职高专）学生一般参加专科组竞赛，也可参加本科组竞赛**，无论参加何组竞赛，均必须在报名时确定，报名截止后不能再更改报名组别。**同一参赛队的学生必须来自同一所学校（同一法人单位）。同一法人单位不能以院（部）系、校区名称参赛（异地办学且具有独立招生代码者除外）。**

“2022 高教社杯全国大学生数学建模竞赛”报名第一次通知

第 1 页

中国工业与应用数学学会

China Society for Industrial and Applied Mathematics

“2022 高教社杯全国大学生数学建模竞赛”报名第一次通知

数模竞赛[2022-01]号

各赛区组委会，各高等院校：

为了培养学生的创新意识及运用数学方法和计算机技术解决实际问题的能力，中国工业与应用数学学会全国大学生数学建模竞赛组委会决定举办2022 高教社杯全国大学生数学建模竞赛（以下简称竞赛），欢迎各高等院校按照竞赛章程、参赛规则及有关规定组织同学报名参赛。

1．2022 年竞赛的时间确定为9 月15 日（周四）18 时至9 月18 日（周日）20 时。

2．参赛者以3 名大学生组成一队（鼓励不写指导教师），通过学校教务部门向所在赛区组委会报名，再由赛区组委会向全国组委会报名。若所在地区尚未成立赛区，由学校直接向全国组委会报名。向全国组委会报名的截止日期为9 月12 日（周一）20 时。

3．报名采用网上报名方式。境内和澳门特别行政区的高校请使用竞赛管理系统报名（https://cumcm.cnki.net）；香港特别行政区的高校请与HKSIAM（https://www.hksiam.org.hk）联系参赛事宜（邮箱：immc.committee@gmail.com）；其他地区高校请访问CUMCM（English Version）（http://en.mcm.edu.cn），按相应要求注册参赛。

4．竞赛分为本科组和专科组进行。本科学生只能参加本科组竞赛，不能参加专科组竞赛。专科（高职高专）学生一般参加专科组竞赛，也可参加本科组竞赛，无论参加何组竞赛，均必须在报名时确定，报名截止后不能再更改报名组别。同一参赛队的学生必须来自同一所学校（同一法人单位）。同一法人单位不能以院（部）系、校区名称参赛（异地办学且具有独立招生代码者除外）。

PDF文件信息提取

MinerU两种后端

- MinerU是一款由上海人工智能实验室 OpenDataLab 团队开发的开源 PDF 转 Markdown 工具，可以高质量地提取 PDF 文档内容，生成结构化的 Markdown 格式文本，可用于RAG、LLM语料准备等场景。
- 官网：https://mineru.net/
- 线上试用：https://www.modelscope.cn/studios/OpenDataLab/MinerU

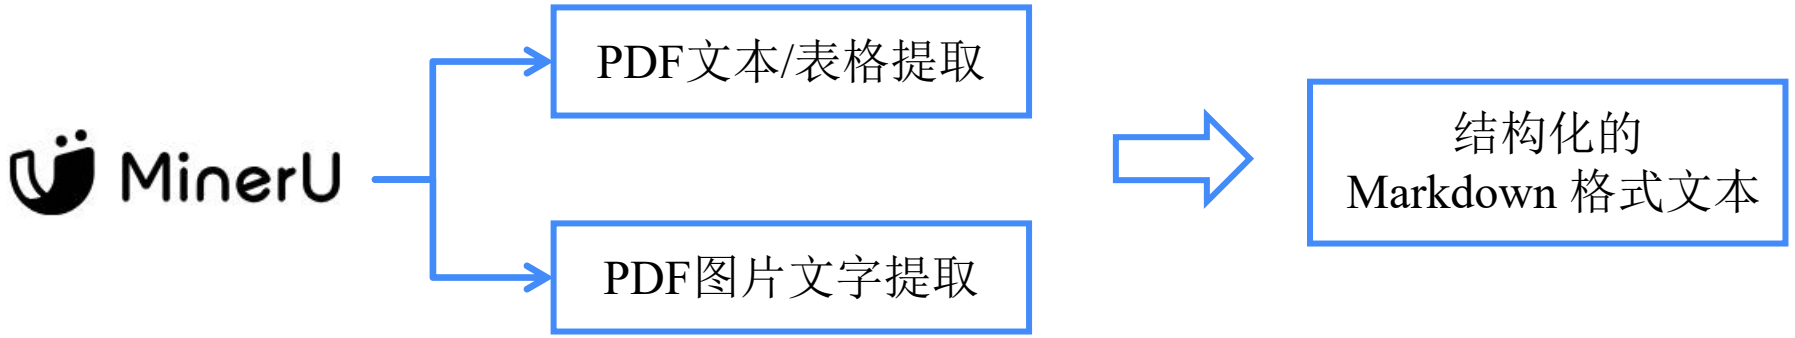

PDF文件信息提取

- MinerU对文档解析的方式有两种，分别是Pipeline和VLM的方式。以下是两种方式的对比。
- **1. VLM 后端（视觉 - 语言模型）**
  - **核心模型：**依赖**视觉 - 语言大模型**（如 Qwen2VL、LLaVA 等），具备“看图理解内容 + 格式”的能力，需配合 vllm 等推理引擎加速（支持批量 / 异步推理）。
  - **辅助工具：**仅需基础的 PDF 转图像工具（如 pdf2image），无需其他专项模型（布局分析、OCR、表格解析等均由大模型内部完成）。
  - **模型特点：**单一大模型包办“识别 + 理解”，依赖强算力（GPU），模型体积大（通常数十亿参数）。
- **2. Pipeline 后端（传统流水线）**
  - **核心模型：**由**多个专项轻量模型 + 规则**组成工具链，分工处理不同任务：
    - 布局分析：DocLayoutYOLO（识别标题、段落、表格等元素位置）；
    - OCR 识别：PaddleOCR（提取图片中的文字）；
    - 表格解析：UnetTableModel（有线表格）、RapidTableModel（无线表格）；
    - 公式处理：YOLOv8MFD（公式检测）+ Unimernet（公式识别为 LaTeX）。
  - **辅助工具：**需要坐标计算（如 IOU 重叠度）、规则匹配（如列表缩进判断）等工程化逻辑。
  - **模型特点：**多模型分工明确，单个模型体积小（百万至千万参数），可在 CPU 运行。

PDF文件信息提取

MinerU安装

- pip install --upgrade pip -i https://mirrors.aliyun.com/pypi/simple
- pip install uv -i https://mirrors.aliyun.com/pypi/simple
- uv pip install -U "mineru[all]" -i https://mirrors.aliyun.com/pypi/simple
  - mineru[all]包含所有核心功能，兼容Windows / Linux / macOS系统，适合绝大多数用户。 如果您需要指定vlm模型的推理框架，或是仅准备在边缘设备安装轻量版client端，可以参考文档扩展模块安装指南（https://opendatalab.github.io/MinerU/zh/quick_start/extension_modules/）。

PDF文件信息提取

MinerU安装

- 默认使用托管在huggingface的模型进行解析，**首次使用时会自动下载所需模型文件**，后续使用将直接加载本地缓存的模型。如果您无法访问huggingface，需要切换至国内镜像源。
  - *import os*
  - *os.environ["MINERU_MODEL_SOURCE"] = "modelscope"*

2. Pipeline 后端（传统流水线）

- **核心模型：**由多个专项轻量模型 + 规则组成工具链，分工处理不同任务：
  - 布局分析：DocLayoutYOLO（识别标题、段落、表格等元素位置）；
  - OCR 识别：PaddleOCR（提取图片中的文字）；
  - 表格解析：UnetTableModel（有线表格）、RapidTableModel（无线表格）；
  - 公式处理：YOLOv8MFD（公式检测）+ Unimernet（公式识别为 LaTeX）。
- **辅助工具：**需要坐标计算（如 IOU 重叠度）、规则匹配（如列表缩进判断）等工程化逻辑。
- **模型特点：**多模型分工明确，单个模型体积小（百万至千万参数），可在 CPU 运行。

PDF文件信息提取

- MinerU的依赖包fasttext需要加载一个本地模型，注意模型的**绝对路径**不要出现中文。

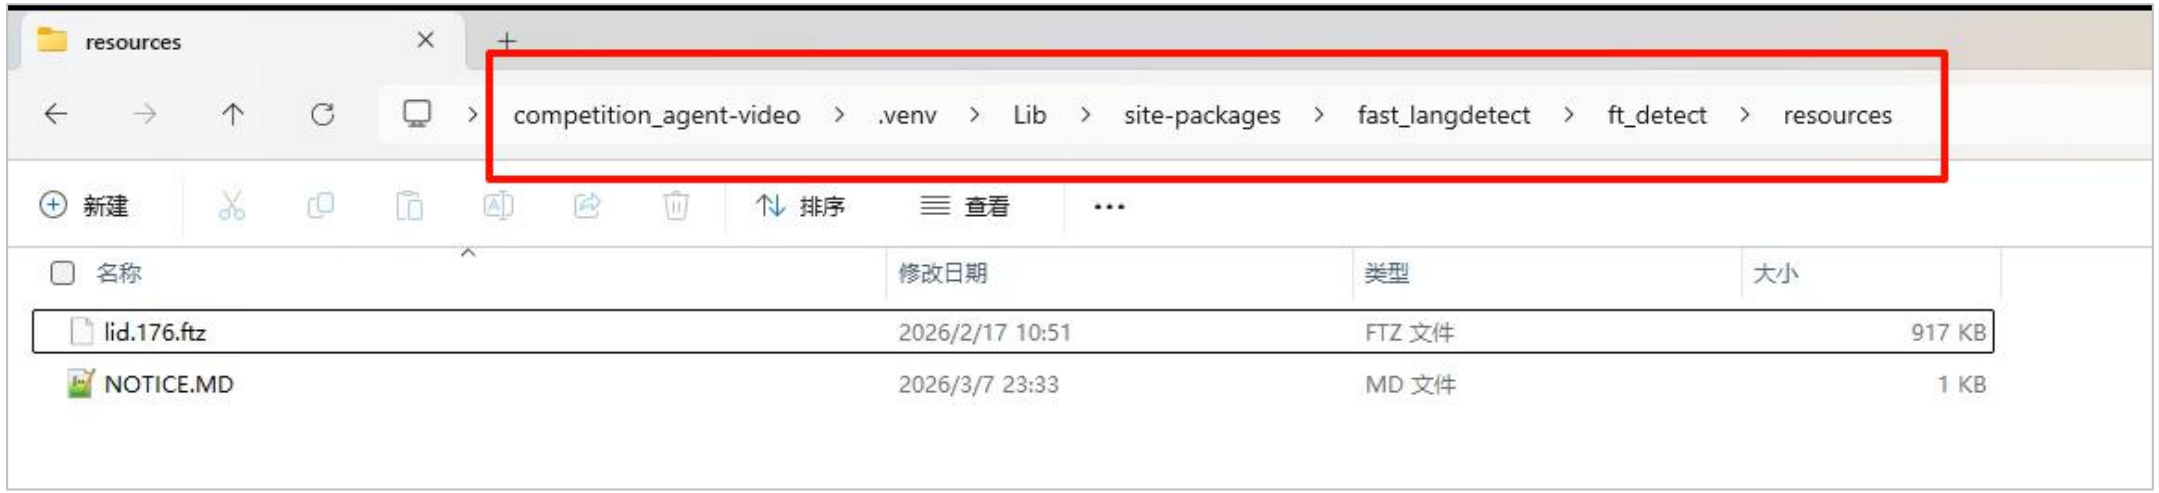

PDF文件信息提取

MinerU

1 将PDF文件读取为二进制字节流

```
from mineru.cli.common import read_fn
pdf_bytes = read_fn( pdf_path )
```

2 裁剪PDF页码

```
from mineru.cli.common import convert_pdf_bytes_to_bytes_by_pypdfium2
processed_bytes = convert_pdf_bytes_to_bytes_by_pypdfium2(
    pdf_bytes,  start_page_id=0,  end_page_id=4
)
```

3 PDF内容解析

```
from mineru.backend.pipeline.pipeline_analyze import doc_analyze as pipeline_doc_analyze
pdf_bytes_list = [processed_bytes]  # 函数传入设定为List[bytes]，需将PDF存列表
# 解析结果、图片列表、PDF文档对象、检测语言、OCR开启状态
infer_results, all_image_lists, all_pdf_docs, lang_list, ocr_enabled_list = pipeline_doc_analyze(
        pdf_bytes_list,
        lang_list = ["auto"]          # 指定每个PDF的解析语言， ["ch"]或者 ["auto"]
        parse_method="auto",    # 解析方法
        formula_enable=True,    # 启用公式解析
        table_enable=True       # 启用表格解析
    )
```

PDF文件信息提取

MinerU

4 统一转为JSON格式

```
from mineru.cli.common import prepare_env
# 准备环境 (创建本地图片和Markdown目录)：输出目录、PDF文件名、解析方法
local_image_dir, local_md_dir = prepare_env(output_dir, pdf_file_name, parse_method)

from mineru.data.data_reader_writer import FileBasedDataWriter
# 创建图片和Markdown写入器
image_writer = FileBasedDataWriter(local_image_dir)
md_writer = FileBasedDataWriter(local_md_dir)

# 转换为中间态 JSON
#   a. 调用 image_writer 把 images_list 里的图片真正保存到硬盘
#   b. 将 model_list 里的结构化数据组装成标准的 JSON 字典
middle_json = pipeline_result_to_middle_json(
    infer_results[0],          # 解析结果
    all_image_lists[0],        # 提取的图片对象列表
    all_pdf_docs[0]            # PDF 文档对象
    image_writer,
    lang_list[0],              # 识别出的语言
    ocr_enabled_list[0],       # OCR 是否启用的状态
    formula_enable=True        # 启用公式解析
)
```

PDF文件信息提取

MinerU

5 将解析结果保存为 Markdown 文件

```
pdf_info = middle_json["pdf_info"]    # 获取中间JSON中的PDF信息
image_dir = str(os.path.basename(local_image_dir))    # 获取图片目录名称

from mineru.backend.pipeline.pipeline_middle_json_mkcontent import union_make as
pipeline_union_make
from mineru.utils.enum_class import MakeMode
# 将 pdf_info转换为 Markdown 字符串
md_content_str = pipeline_union_make(
        pdf_info,
        MakeMode.MM_MD,  # Markdown生成模式，默认为MakeMode.MM_MD
        image_dir)

# 写入文件
md_writer.write_string(
        f"{pdf_file_name}.md",      # 写入md文件名
        md_content_str,             # 写入的内容
    )
```

PDF文件信息提取

➢ 使用MinerU进行PDF文件信息提取。

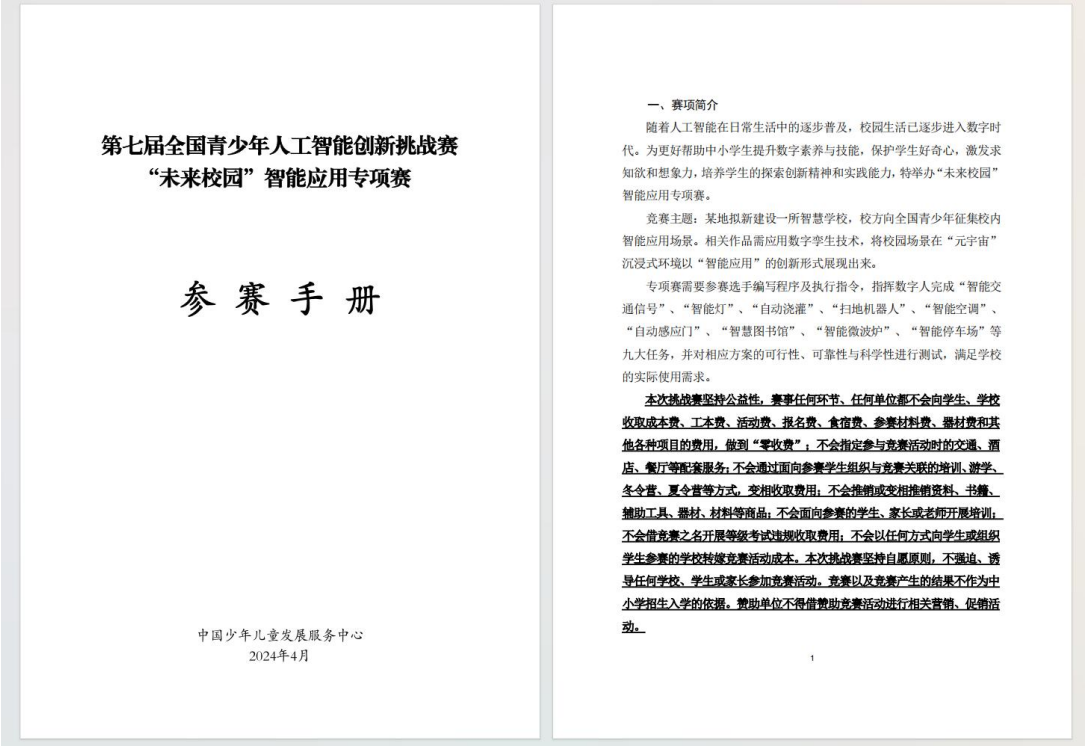

第七届全国青少年人工智能创新挑战赛
“未来校园”智能应用专项赛

参 赛 手 册

中国少年儿童发展服务中心
2024年4月

一、赛项简介

随着人工智能在日常生活中的逐步普及，校园生活已逐步进入数字时代。为更好帮助中小学生提升数字素养与技能，保护学生好奇心，激发求知欲和想象力，培养学生的探索创新精神和实践能力，特举办“未来校园”智能应用专项赛。

竞赛主题：某地拟新建设一所智慧学校，校方向全国青少年征集校内智能应用场景。相关作品需应用数字孪生技术，将校园场景在“元宇宙”沉浸式环境以“智能应用”的创新形式展现出来。

专项赛需要参赛选手编写程序及执行指令，指挥数字人完成“智能交通信号”、“智能灯”、“自动浇灌”、“扫地机器人”、“智能空调”、“自动感应门”、“智慧图书馆”、“智能微波炉”、“智能停车场”等九大任务，并对相应方案的可行性、可靠性与科学性进行测试，满足学校的实际使用需求。

本次挑战赛坚持公益性，赛事任何环节、任何单位都不会向学生、学校收取成本费、工本费、活动费、报名费、食宿费、参赛材料费、器材费和其他各种项目的费用，做到“零收费”；不会指定参与竞赛活动时的交通、酒店、餐厅等配套服务；不会通过面向参赛学生组织与竞赛关联的培训、游学、冬令营、夏令营等方式，变相收取费用；不会推销或变相推销资料、书籍、辅助工具、器材、材料等商品；不会面向参赛的学生、家长或老师开展培训；不会借竞赛之名开展等级考试违规收取费用；不会以任何方式向学生或组织学生参赛的学校转嫁竞赛活动成本。本次挑战赛坚持自愿原则，不强迫、诱导任何学校、学生或家长参加竞赛活动。竞赛以及竞赛产生的结果不作为中小学招生入学的依据。赞助单位不得借赞助竞赛活动进行相关营销、促销活动。

1

```
1  # 第七届全国青少年人工智能创新挑战赛“未来校园”智能应用专项赛
2
3  # 参赛手 册
4
5  中国少年儿童发展服务中心2024年4月
6
7  # 一、赛项简介
8
9  随着人工智能在日常生活中的逐步普及，校园生活已逐步进入数字时代。为更好帮助中小学生提升数字素养与技能，保护学生好奇心，激发求知欲和想象力，培养学生的探索创
   新精神和实践能力，特举办“未来校园”智能应用专项赛。
10
11 竞赛主题：某地拟新建设一所智慧学校，校方向全国青少年征集校内智能应用场景。相关作品需应用数字孪生技术，将校园场景在“元宇宙”沉浸式环境以“智能应用”的创新形式
   展现出来。
12
13 专项赛需要参赛选手编写程序及执行指令，指挥数字人完成“智能交通信号”、“智能灯”、“自动浇灌”、“扫地机器人”、“智能空调”、“自动感应门”、“智慧图书馆”、“智能微波炉”
   、“智能停车场”等九大任务，并对相应方案的可行性、可靠性与科学性进行测试，满足学校的实际使用需求。
14
15 本次挑战赛坚持公益性，赛事任何环节、任何单位都不会向学生、学校收取成本费、工本费、活动费、报名费、食宿费、参赛材料费、器材费和其他各种项目的费用，做到“零收费”
   ；不会指定参与竞赛活动时的交通、酒店、餐厅等配套服务；不会通过面向参赛学生组织与竞赛关联的培训、游学、冬令营、夏令营等方式，变相收取费用；不会推销或变相推销资
   料、书籍、辅助工具、器材、材料等商品；不会面向参赛的学生、家长或老师开展培训；不会借竞赛之名开展等级考试违规收取费用；不会以任何方式向学生或组织学生参赛的学校
   转嫁竞赛活动成本。本次挑战赛坚持自愿原则，不强迫、诱导任何学校、学生或家长参加竞赛活动。竞赛以及竞赛产生的结果不作为中小学招生入学的依据。赞助单位不得借赞助竞
   赛活动进行相关营销、促销活动。
16
17 # 二、参赛条件及分组办法
18
19 # （一）参赛要求
20
21 1.在校小学、初中、高中、中专或职高学生均可参赛。
22
23 2.选手所在学段组别分为：小学组、初中组、高中组(含中专、职高)。
24
25 3.未来校园智能应用专项赛为个人赛，每位参赛选手对应一位指导教师，一位指导教师可对应多位学生。
26
27 4.指导教师作为责任人，有责任监督竞赛期间参赛选手关注人身、财产安全，指导参赛选手制定学习计划，督促参赛选手顺利完成比赛。
28
29 # （二）比赛环境
30
```

目录

01 实现思路

02 PDF文件信息提取

03 本地构建RAG应用

04 竞赛客服机器人开发

05 答疑环节

本地构建RAG应用

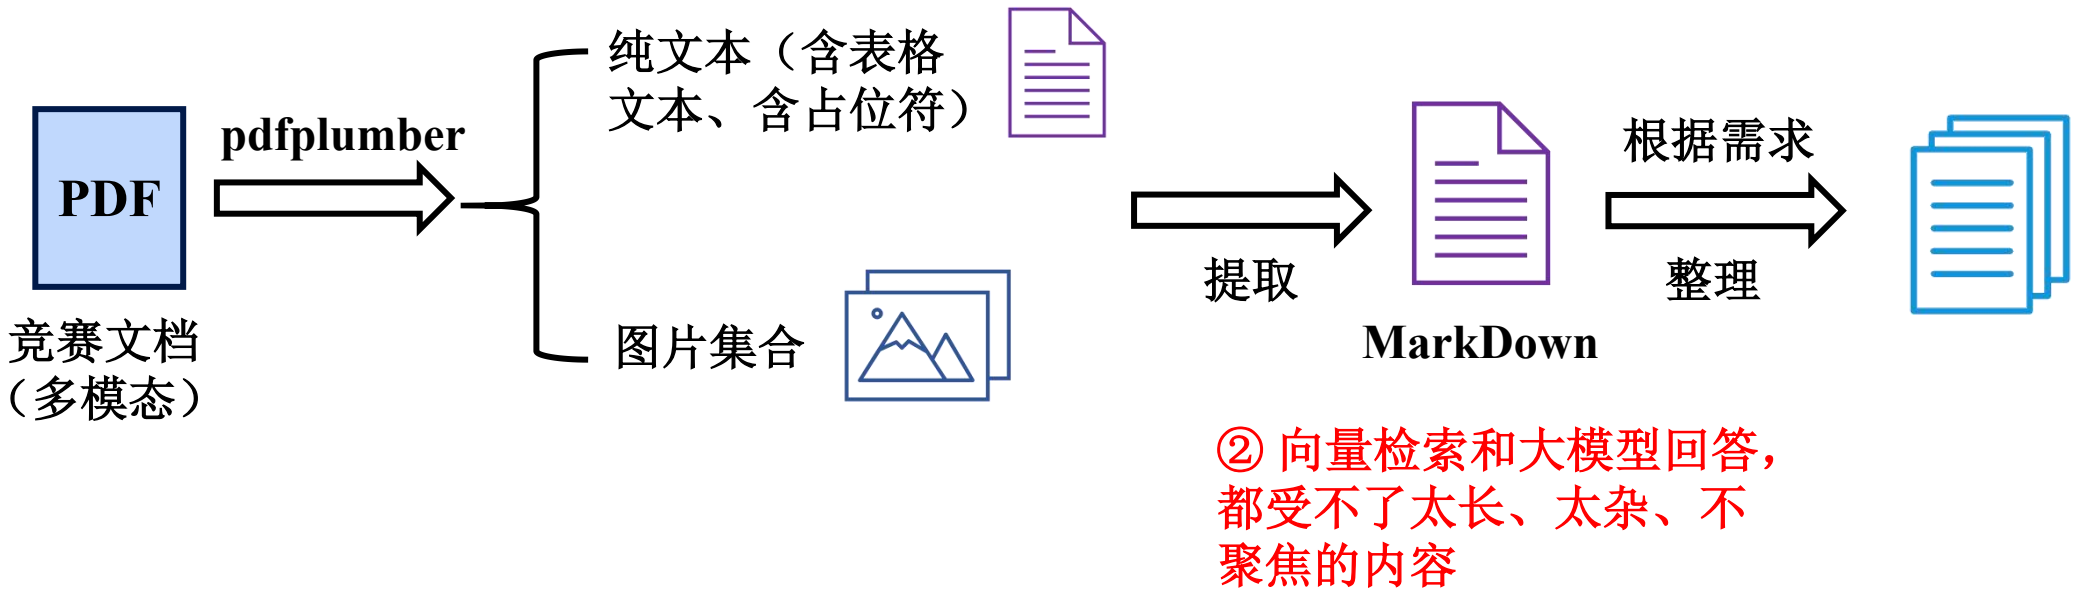

思路：
1、从竞赛文档中抽取核心的竞赛信息以结构化的数据形式存储下来
2、其他竞赛信息将文档分块转换为向量，存储至向量数据库

本地构建RAG应用

- 依据附件 1 中竞赛规程文档，获取各个竞赛的基本信息。

赛项名称	赛道	发布时间	报名时间	组织单位	官网
第七届全国青少年人工智能创新挑战赛	‘未来校园’智能应用专项赛	2024年4月	2024年4月15日-2024年5月15日	中国少年儿童发展服务中心	https://aiic.china61.org.cn/

本地构建RAG应用

RAG是什么

- 检索增强生成（Retrieval-Augmented Generation，RAG）是一种结合了信息检索和语言模型的技术，它通过从大规模的知识库中检索相关信息，并利用这些信息来指导语言模型生成更准确和深入的答案。这种方法在2020年由Meta AI研究人员提出，旨在解决**大型语言模型（LLM）在信息滞后、模型幻觉、私有数据匮乏和内容不可追溯等问题**。

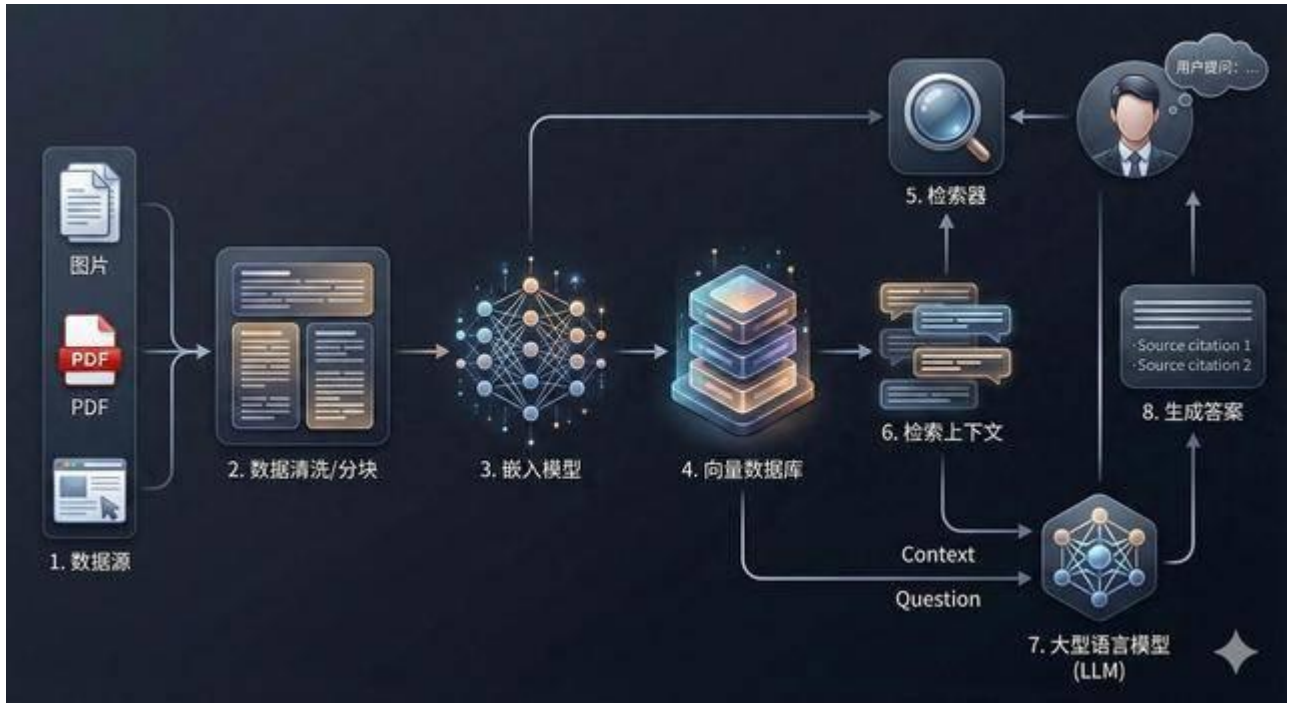

本地构建RAG应用

- RAG 的主要流程主要包含以下 2 个阶段：
  1. 数据准备阶段： 管理员将内部私有数据向量化后入库的过程，向量化是一个将文本数据转化为向量矩阵的过程，该过程会直接影响到后续检索的效果；入库即将向量数据构建索引，并存储到向量数据库的过程。
  2. 用户应用阶段： 根据用户的 Prompt 提示词，通过检索召回与 Prompt 提示词相关联的知识，并融入到原 Prompt 提示词中，作为大模型的输入 Prompt 提示词，通用大模型因此生成相应的输出。

- Llamaindex+Ollama 构建RAG私有化知识库
  - **LlamaIndex: 一个数据框架，用于连接大语言模型与您的私有数据（如文档、数据库）**。它通过创建索引（如向量索引）来高效组织和检索信息，解决大模型“知识滞后”和“幻觉”问题。
  - Ollama: 一个用于在本地轻松下载、运行和管理开源大语言模型（如 Qwen、Mistral、Llama3）的工具。它提供了一个本地API（默认端口11434），让 LlamaIndex 能够调用这些模型。

本地构建RAG应用

- LlamaIndex是一个专注增强LLM**数据处理**和**查询能力**的工具库，用于**数据注入**、**数据结构化**、并**访问私有或特定领域数据，解决数据和大模型之间的衔接问题**（将需要访问的私有或特定领域的数据分散在不同的应用程序和数据存储中）
  - 数据注入：将私有或特定领域数据引入到大模型的过程（使LLM能够在特定的上下文或领域中更好的理解和生成信息）
  - 数据结构化：将非结构化的数据转变成结构化格式的过程（自由文本、图片-->表格或数据库格式）
- RAG（检索增强生成）：检索个人或私域数据来增强LLM的一种范式（**用于解决大模型幻觉问题**）
  - **索引阶段**
  - **查询阶段**
- https://developers.llamaindex.ai/

本地构建RAG应用

LlamaIndex五大核心工具

- 数据连接器（Data Connectors）
- 数据索引（Data Indexes）
- 引擎（Engines）
- 数据代理（Data Agents）
- 应用集成（Application Integrations）

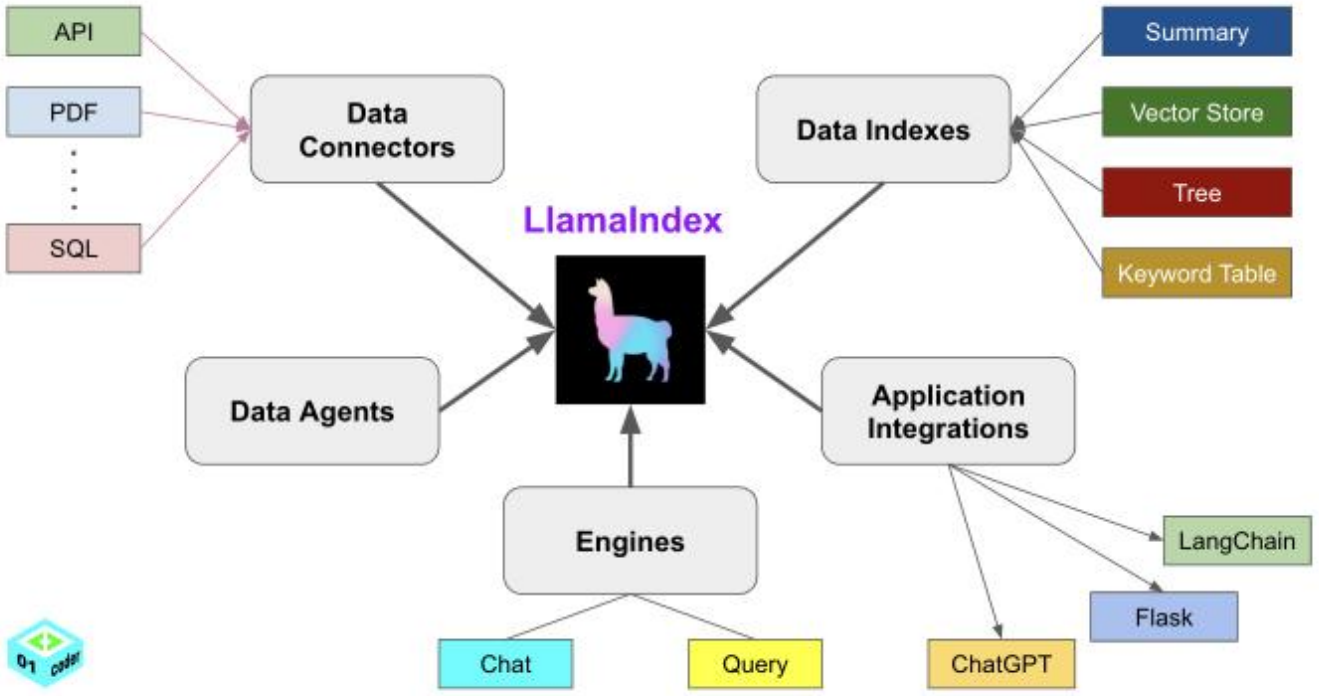

本地构建RAG应用

LlamaIndex五大核心工具

- **数据连接器（Data Connectors）**：用于从多样化源数据中提取数据并转换为结构化文档（Document对象：文本和元数据）
  - from llama_index import SimpleDirectoryReader
  - documents = SimpleDirectoryReader("./data").load_data() # 加载本地数据
- **数据索引（Data Indexes）**：将原始数据构建成为高效查询的索引结构（向量索引：通过嵌入模型将文本转换为词向量）
  - from llama_index import VectorStoreIndex
  - index = VectorStoreIndex.from_documents(documents) # 创建向量索引
  - index.storage_context.persist(persist_dir="./storage") # 持久化索引

本地构建RAG应用

LlamaIndex五大核心工具

- **引擎（Engines）：**用于加载大模型（查询引擎、聊天引擎）
  - query_engine = index.as_query_engine()
  - response = query_engine.query("LlamaIndex的核心功能是什么？") # 执行查询
  - chat_engine = index.as_chat_engine()
  - response = chat_engine.chat("请解释数据索引的作用。") # 多轮对话

本地构建RAG应用

LlamaIndex五大核心工具

- **数据代理（Data Agents）：** 由LLM驱动的智能代理，通过工具自动化处理数据任务
  - **Agent = LLM（大脑） + Tools（手脚）：** 通过自然语言理解任务，动态选择工具执行
  - 核心价值：将静态的RAG系统升级为自主迭代的智能体

```
from llama_index.core.agent import ReActAgent
from llama_index.core.tools import QueryEngineTool
# 将查询引擎封装为工具供Agent调用
tool = QueryEngineTool.from_defaults(query_engine=query_engine)
agent = ReActAgent.from_tools([tool], llm=llm)
response = agent.chat("总结最近新增文档的核心观点")
```

本地构建RAG应用

LlamaIndex五大核心工具

- **应用集成（Application Integrations）：**提供丰富的应用集成选项（如向量数据库集成、应用框架集成和与模型服务的对接）
  - from llama_index.vector_stores.chroma import ChromaVectorStore
  - import chromadb
  - # 连接Chroma数据库
  - chroma_client = chromadb.PersistentClient(path="./chroma_db")
  - vector_store=ChromaVectorStore(chroma_collection=chroma_client.create_collection("docs"))
  - index = VectorStoreIndex.from_documents(documents,vector_store=vector_store)

本地构建RAG应用

Ollama

- Ollama是一个专为在本地机器上便捷部署和运行大型语言模型（LLM）而设计的开源框架，降低了使用大语言模型的门槛，使得大模型的开发者、研究人员和爱好者能够在本地环境快速实验、管理和部署最新大语言模型，包括如Llama 3、Phi 3、Mistral、Gemma等开源的大型语言模型。
- 下载安装： https://ollama.com/download/windows
- 常用指令：
  - ollama serve：启动 ollama 服务。
  - ollama show：显示某个模型的详细信息。
  - ollama run <模型名称>：运行一个模型。
  - ollama stop <模型名称>：停止一个正在运行的模型。
  - ollama pull <模型名称>：从一个模型仓库（registry）拉取一个模型。
  - ollama push <模型名称>：将一个模型推送到一个模型仓库。
  - ollama list：列出所有模型。
  - ollama ps：列出所有正在运行的模型。
  - ollama cp <模型名称>：复制一个模型。
  - ollama rm <模型名称>：删除一个模型。
  - ollama help <命令名称>：获取关于任何命令的帮助信息。

本地构建RAG应用

Ollama

- Ollama支持的模型：https://ollama.com/search

命令 (Command)	说明 (Description)	示例 (Example)
ollama run	**运行模型**。如果不存在则自动拉取。	ollama run llama3
ollama pull	**拉取模型**。从库中下载模型但不运行。	ollama pull mistral
ollama list	**列出模型**。显示本地所有已下载的模型。	ollama list
ollama rm	**删除模型**。移除本地模型释放空间。	ollama rm llama3
ollama cp	**复制模型**。将现有模型复制为新名称（用于测试）。	ollama cp llama3 my-model
ollama create	**创建模型**。根据 Modelfile 创建自定义模型（高级）。	ollama create my-bot -f ./Modelfile
ollama show	**显示信息**。查看模型的元数据、参数或 Modelfile。	ollama show --modelfile llama3
ollama ps	**查看进程**。显示当前正在运行的模型及显存占用。	ollama ps
ollama push	**推送模型**。将你自定义的模型上传到 ollama.com。	ollama push my-username/my-model
ollama serve	**启动服务**。通常后台自动运行。	ollama serve
ollama help	**帮助**。查看任何命令的帮助信息。	ollama help run

本地构建RAG应用

操作

- 竞赛信息提取：从markdown文件中提取竞赛的关键信息（竞赛名称、赛道、发布时间、报名时间等），并整理为csv文件。

1 LLM配置

```
llm = Ollama(
    model="qwen3:1.7b",
    request_timeout=3600.0,
    temperature=0.0,
    base_url="http://localhost:11434"
)
```

2 设定提示词

角色：信息提取助手
任务：以JSON格式提取参赛信息

```
# 提示词模板
extract_prompt = PromptTemplate(
    "你是一个专业的信息提取助手。请从以下文档内容中，提取出以下字段的信息：\n"
    "1. 赛项名称：竞赛的完整官方名称，不遗漏核心关键词\n"
    "2. 赛道：赛项下的细分赛道/类别\n"
    "3. 发布时间：赛事通知/报名公告的官方发布时间\n"
    "4. 报名时间：官方指定的报名起止时间，需保留完整日期范围\n"
    "5. 组织单位：赛事的主办/承办单位全称\n"
    "6. 官网：赛事官方报名/查询网址，需包含完整 URL\n\n"
    "如果文档中没有明确提到某个字段，对应字段值为 null。\n"
    "文档内容：\n{doc_content}\n\n"
    "请严格按照以下JSON格式输出，不要添加任何其他说明：\n"
    "{{\n"
    "  \"赛项名称\": \"\",\n"
    "  \"赛道\": \"\",\n"
    "  \"发布时间\": \"\",\n"
    "  \"报名时间\": \"\",\n"
    "  \"组织单位\": \"\",\n"
    "  \"官网\": \"\"\n"
    "}}"
)
```

本地构建RAG应用

操作

- 竞赛信息提取：从markdown文件中提取竞赛的关键信息（竞赛名称、赛道、发布时间、报名时间等），并整理为csv文件。

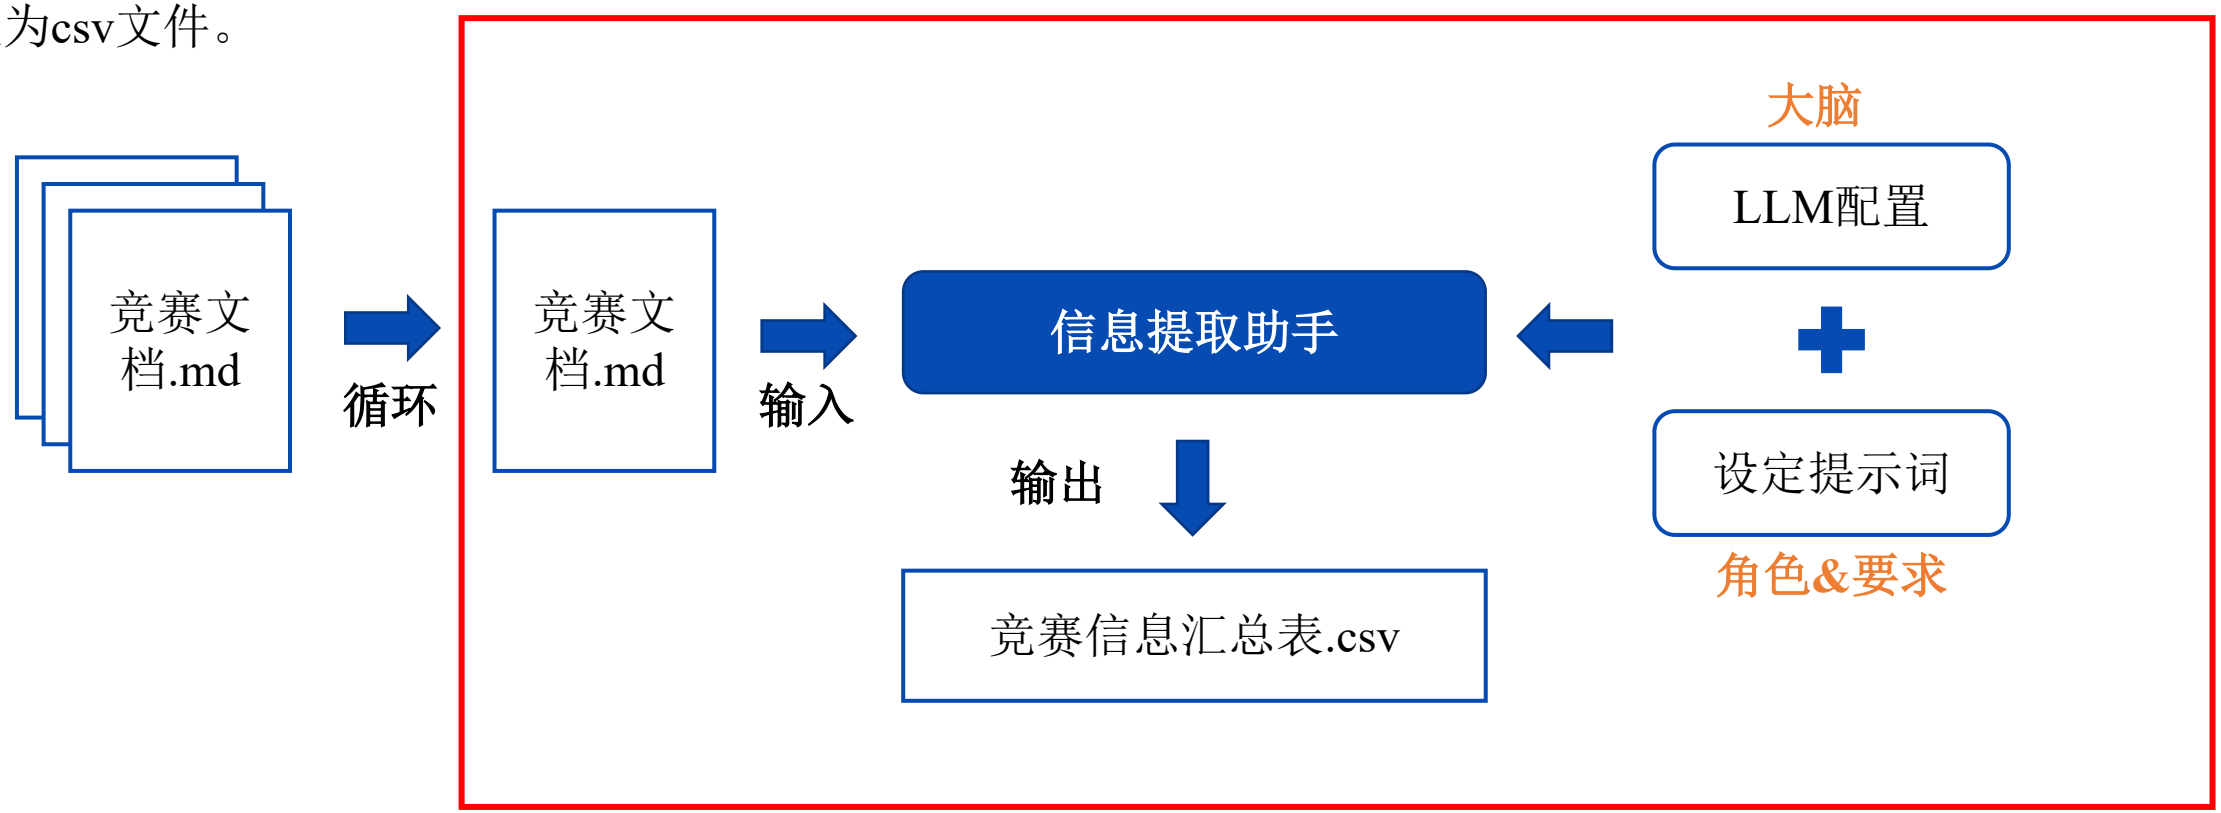

本地构建RAG应用

操作
本地构建RAG应用

Ollama

Embedding 模型
Settings.embed_model = HuggingFaceEmbedding(model_name="bge-large-zh-v1.5")

LLM 模型
Settings.llm = Ollama(model="qwen3:1.7b", request_timeout=360.0)

LlamaIndex

批量加载MD文件
llama_index.core.SimpleDirectoryReader()

Markdown 文件

将文档分块转换为向量
llama_index.core.node_parser.SentenceSplitter()

parser = SentenceSplitter(chunk_size=512)
nodes = parser.get_nodes_from_documents(md)

nodes
文本块

数据索引/检索

设置本地 Embedding 模型

构建向量索引

index =llama_index.core.load_index_from_storage (storage_context,embed_model)

查询引擎
index.as_query_engine(llm=Settings.llm)

问题

回答

目录

01 实现思路

02 PDF文件信息提取

03 本地构建RAG应用

04 竞赛客服机器人开发

05 答疑环节

竞赛客服机器人开发

网页前端展示

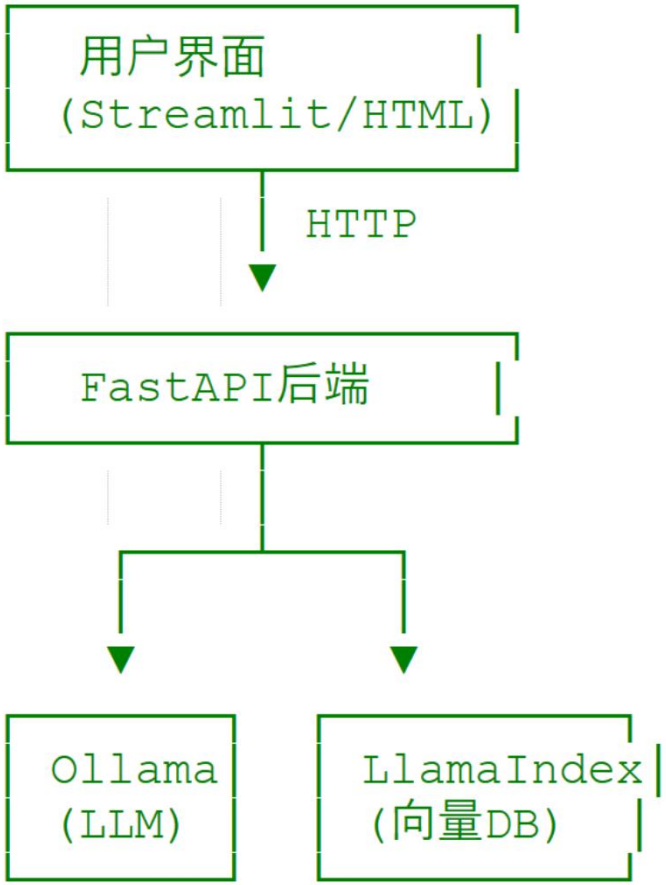

FastAPI后端

- FastAPI 是一个用于构建 API 的现代、快速（高性能）的 Web 框架，使用 Python 并基于标准的 Python 类型提示。
- 关键特性：
  - 快速：极高性能，可与 NodeJS 和 Go 并肩（归功于 Starlette 和 Pydantic）。最快的 Python 框架之一。
  - 高效编码：功能开发速度提升约 200% ～ 300%。*
  - 更少 bug：人为（开发者）错误减少约 40%。*
  - 直观：极佳的编辑器支持。处处皆可自动补全。更少的调试时间。
  - 易用：为易用和易学而设计。更少的文档阅读时间。
  - 简短：最小化代码重复。一次参数声明即可获得多种功能。更少的 bug。
  - 健壮：生产可用级代码。并带有自动生成的交互式文档。
  - 标准化：基于（并完全兼容）API 的开放标准：OpenAPI（以前称为 Swagger）和 JSON Schema。

竞赛客服机器人开发

FastAPI后端

- 帮开发者快速、安全、高效地搭建和使用“软件之间的连接通道”。

- 文档：https://fastapi.tiangolo.com
- 源码：https://github.com/tiangolo/fastapi
- 安装：pip install fastapi unvicorn

端点	方法	说明
`/`	GET	API根路径，返回说明
`/api/health`	GET	健康检查，显示系统状态
`/api/answer`	GET	获取问题答案，RAG检索
`/api/questions`	GET	获取所有预设问题
`/api/competitions`	GET	获取所有竞赛信息
`/api/competitions/search`	GET	搜索竞赛信息
`/api/competitions/details`	GET	获取竞赛详情
`/api/data/reload`	GET	热重载数据

竞赛客服机器人开发

FastAPI后端

1 初始化准备

- 创建 FastAPI 应用实例并配置 CORS 跨域支持
- 加载配置文件 (config.py)
- 初始化全局变量存储竞赛数据、问题库和查询引擎

2 数据加载

- 加载向量数据库查询引擎 (用于智能问答)
- 尝试从 JSON/CSV 文件加载竞赛信息数据
- 加载问题库数据 (Excel 文件)

3 设置API 接口

- /api/health - 健康检查接口
- /api/data/reload - 数据重载接口
- /api/answer - 智能问答接口 (使用向量数据库)
- /api/questions - 获取所有问题
- /api/competitions - 获取所有竞赛信息
- /api/competitions/search - 竞赛信息搜索
- /api/competitions/details - 竞赛详情查询

4 服务启动

- 使用 uvicorn 启动服务 (默认端口 8001)
- 提供 Swagger 文档接口 (/docs)

竞赛客服机器人开发

➢ 一个页面的开发流程是这样的：

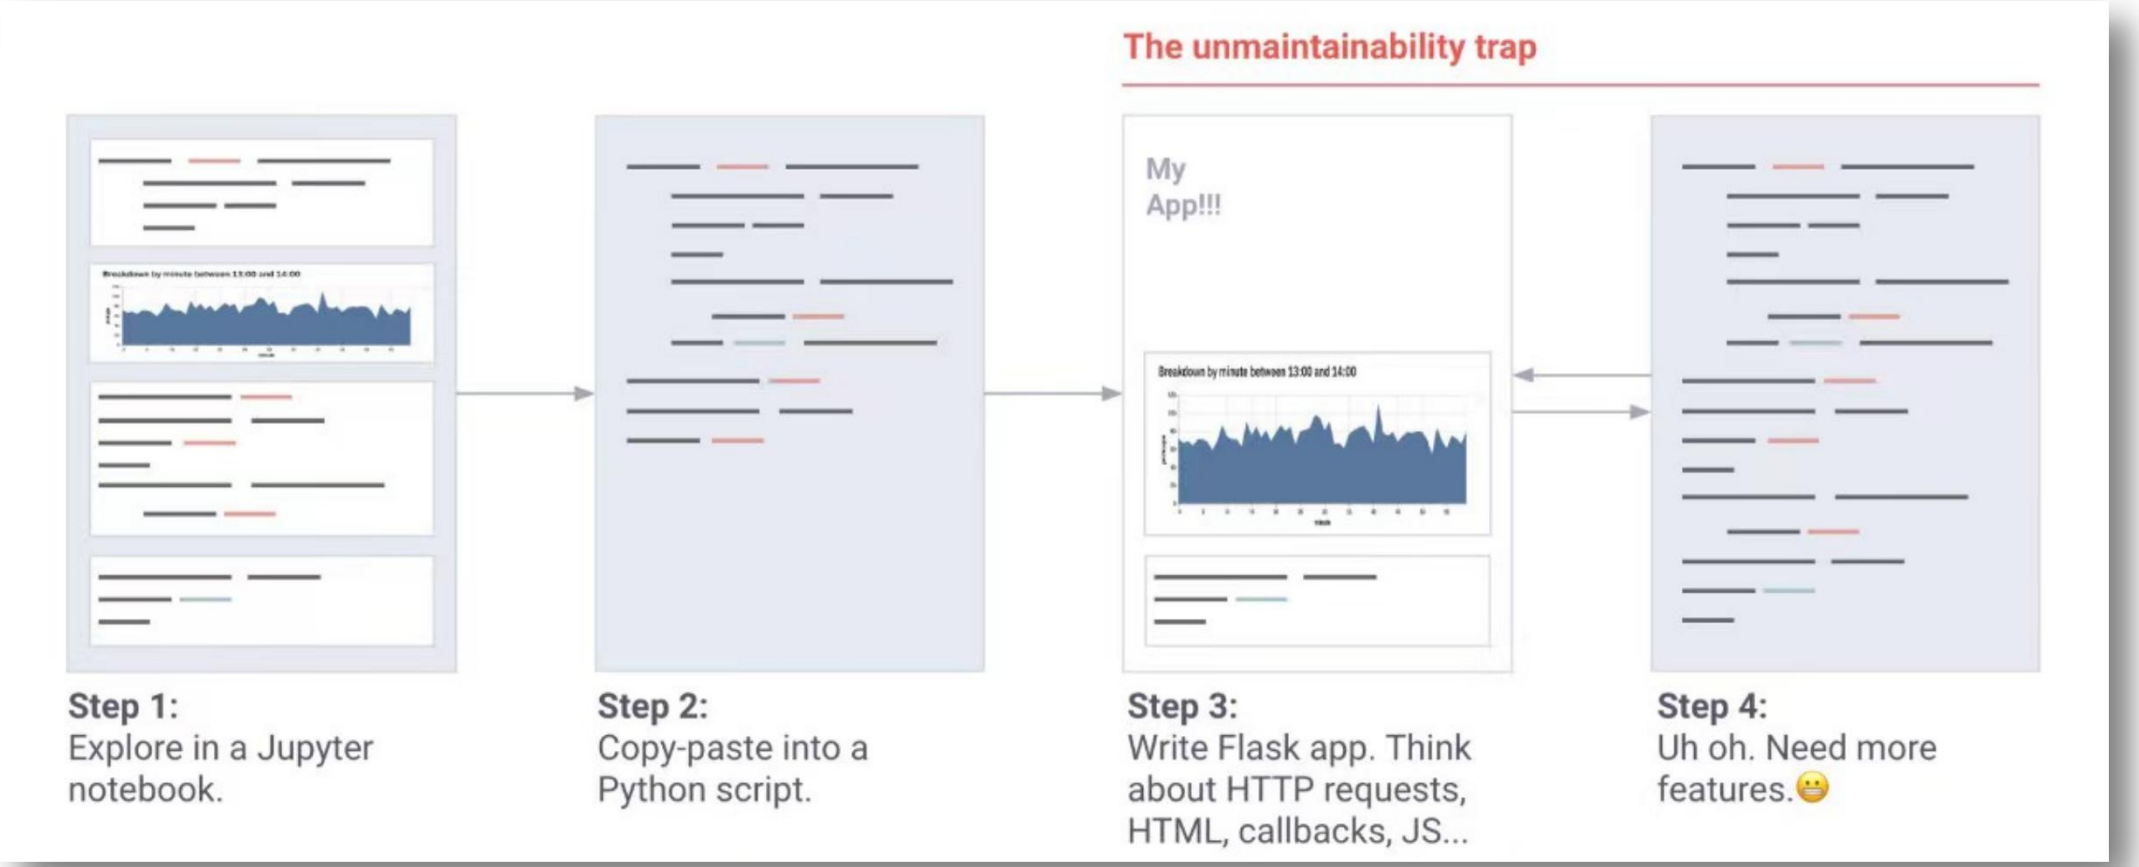

竞赛客服机器人开发

Streamlit的催生

- 在数据科学领域，一方面，当我们在学习或者实践机器学习算法的时候，需要进行一些参数调整；另一方面，我们也希望将最后的成果通过一种友好的可视化效果呈现出来。
- 虽然可以通过Django、Flask等技术构建Web App，但是它们对于非专业的编程者来说，初学是困难的。
- **Streamlit是一种快速搭建数据可视化APP的技术**。它上手简单，并且能够提供一些操作简单的交互式控件。

- Streamlit主页：https://streamlit.io/
- 帮助文档：https://docs.streamlit.io/

竞赛客服机器人开发

常见功能

文本组件

- 用来在网页展示各种类型的文本内容。
- 纯文本、Markdown、标题、代码和LaTeX公式。

多媒体组件

- 展示图片、音频和视频等多媒体

数据组件

- 展示表格

状态组件

- 向用户展示当前程序的运行状态

图表组件

- 主要包含两部分，一部分是原生组件，另一部分是渲染第三方库

其他内容

- 页面布局、控制流和缓存。

输入组件

- 接受用户的输入

竞赛客服机器人开发

常用命令（在CMD环境使用）

- streamlit run your_app.py # 启动运行APP
- streamlit config show # 显示配置文档
- streamlit cache clear # 清除缓存

- 当源代码被修改，无需重启服务，在页面上点击刷新按钮就可加载最新的代码，运行和调试都非常方便。

竞赛客服机器人开发

RUNNING...
Stop
Deploy
竞赛客服智能体
检查系统状态
系统状态: unknown
数据操作
重新加载数据
关于
清除对话历史
竞赛客服智能体
第七届全国青少年人工智能创新挑战赛的报名时间是什么时候?
第七届全国青少年人工智能创新挑战赛的报名时间为2024年4月15日至5月15日。
参考来源:
11_生成式人工智能应用专项赛.md
07_竞技机器人专项赛.md
查看所有竞赛列表
根据提供的上下文信息，目前提及的竞赛列表包括:
1. 第12届"泰迪杯"数据挖掘挑战赛（每年3月举办，规则及评奖办法详见文件内容）
2. 编程创作与信息学专项赛（包含联系方式及知识产权声明）
以上为上下文明确提及的竞赛项目。
参考来源:
04_编程创作与信息学专项赛.md
03_2024年（第12届）"泰迪杯"数据挖掘挑战赛竞赛通知.md
请输入您的问题...

总结

本项目已成功完成竞赛客服智能体的搭建，包含后端API、前端界面。

1. 完全本地化：所有模型和数据本地运行，无外部依赖
2. RAG增强：基于向量数据库的智能检索
3. 后端、前端搭建：Streamlit前端展示和fastAPI后端搭建
4. 代码模块化：清晰的模块划分，易于维护

目录

01 实现思路

02 PDF文件信息提取

03 本地构建RAG应用

04 竞赛客服机器人开发

05 答疑环节

答疑环节

若对本次直播有疑问或咨询赛题信息，可在聊天框内发消息